宏观视角：构建多层、互补的AI安全体系

忏悔机制是AI安全与透明化工具栈中的一层，与其他方法相辅相成，共同构建一个更强大的系统。

NotebookLM